

# Introducción teórico-matemática a los problemas de decisión estática bajo incertidumbre

---

Este documento presenta una **introducción formal** a la formulación y análisis de **problemas de decisión estática bajo incertidumbre**. Su objetivo es exponer los elementos esenciales — definiciones, ecuaciones y enfoques heurísticos — que permiten mapear un problema real a este marco teórico, proporcionando también la **intuición** necesaria para su aplicación práctica.

La exposición se asume para lectores con base en teoría de la probabilidad y teoría de la decisión, pero que necesiten un **recorrido conceptual** que integre los componentes clave de la **incertidumbre**, la **información parcial** (o "proxy") y el **razonamiento heurístico**.

---

## 1. Fundamentos de los problemas de decisión bajo incertidumbre

### 1.1 Definición básica

En un **problema de decisión estática** bajo incertidumbre, un **decisor** (o **agente**) debe **elegir** una acción (o un conjunto de acciones) **antes** de conocer con certeza el estado del mundo que afectará el resultado. Formulemos estos elementos:

- $\Omega$ : **Espacio de estados** o **estados de la naturaleza**. Cada  $\omega \in \Omega$  representa una configuración posible del mundo.
- $D$ : **Espacio de decisiones**. Cada  $d \in D$  es una acción o estrategia completa que el agente puede tomar.
- $\mathcal{X}(\omega, d)$ : **Resultado** (o **outcome**) resultante de la decisión  $d$  cuando el estado del mundo es  $\omega$ . A veces se modela como un **pago/beneficio** (o "payoff"), otras veces como un **costo** o **utilidad**.

El decisor generalmente no sabe **a priori** cuál es  $\omega$ , pero dispone de un **modelo probabilístico**  $p(\omega)$  que indica la probabilidad (o densidad) de cada estado. Suponemos que:

$$\sum_{\omega \in \Omega} p(\omega) = 1$$

(o la integral se iguala a 1, en el caso continuo).

### 1.2 Función de utilidad o métricas de evaluación

Para evaluar las decisiones, suele usarse una **función de utilidad**  $U(\omega, d)$  o, alternativamente, una **función de pérdidas** o **ganancias**. En muchos casos, se define:

$$U(\omega, d) = u(\mathcal{X}(\omega, d))$$

donde  $u$  es una transformación (posiblemente el "valor monetario" o alguna función de preferencia).

## Valor esperado de la utilidad

En la teoría de la decisión clásica, el decisor busca **maximizar** (o minimizar) la **esperanza** de su utilidad (o costo). Así, el **criterio de Valor Esperado (VE)** se expresa como:

$$\mathbb{E}[U(d)] = \sum_{\omega \in \Omega} p(\omega) U(\omega, d)$$

(En caso continuo, se reemplaza la suma por la integral respectiva). La **decisión óptima** se define como:

$$d^* = \arg \max_{d \in D} \mathbb{E}[U(d)]$$

## 1.3 Decisión estática vs. dinámica

- **Estática:** El agente escoge su acción completa **antes** de observar la realización de  $\omega$ . (La información disponible antes de la decisión es la misma para todo el horizonte del problema).
- **Dinámica:** Existen decisiones secuenciales, donde el agente puede ir actualizando su información y tomando nuevas decisiones sobre la marcha.

En este documento, nos centraremos en el **caso estático**.

---

## 2. Incertidumbre e información parcial

En muchos problemas, el decisor no observa  $\omega$  **directamente**, sino que recibe **información parcial**, a menudo ruidosa o incompleta, acerca del verdadero estado. Llamemos a esta información un **"proxy"** o un **vector de observaciones**  $Z$ .

### 2.1 Variables aleatorias y distribución condicional

Sea  $Z$  una variable (o conjunto de variables) aleatoria(s) con la distribución  $p(z \mid \omega)$ . Al obtener el valor observado  $z$ , el decisor puede actualizar su creencia sobre  $\omega$  usando la **regla de Bayes**:

$$p(\omega \mid z) = \frac{p(z \mid \omega)p(\omega)}{\sum_{\omega' \in \Omega} p(z \mid \omega')p(\omega')}$$

En muchos problemas prácticos, **no** se dispone de  $p(z \mid \omega)$  exacta, sino que se recurre a **estimaciones, modelos simplificados o correlaciones empíricas**.

### 2.2 Formulación de un problema con información parcial

El decisor recibe  $Z = z$  y luego **selecciona**  $d$ . En la versión **estática** pura, puede ocurrir que:

- El decisor **no pueda** observar  $z$  en el momento de decidir (o lo observa pero la acción no puede cambiar).
- O bien el decisor observa  $z$  y, **sin más interacciones posteriores**, elige  $d$ .

En cualquier caso, la **estrategia** puede definirse como una función  $\delta$  que asocia cada valor posible de  $z$  a una decisión  $\delta(z)$ . Esta visión se generaliza fácilmente al marco de la decisión estática con "observaciones previas".

### 3. Mapeo de problemas reales a esta formulación

Para "ver" un problema real como un **problema de decisión estática** bajo incertidumbre:

1. **Identificar las decisiones** ( $D$ ): ¿Qué conjunto de acciones estratégicas se tienen disponibles?
2. **Modelar el estado de la naturaleza** ( $\Omega$ ): ¿Cuáles son las circunstancias exógenas (incertidumbre) relevantes?
3. **Definir la función de utilidad (o costo)**: ¿Cómo valorar cada outcome? ¿Cuáles criterios se priorizan (tiempo, riesgo, costos, etc.)?
4. **Establecer el modelo probabilístico**:
  - ¿Cómo se distribuyen los estados  $\omega$ ?
  - ¿Qué información parcial/proxy existe (variables  $Z$ )?
  - ¿Cómo se relaciona  $Z$  con  $\omega$ ? (p.ej.  $p(z \mid \omega)$  estimado o supuesto).
5. **Evaluar** las posibles decisiones con la esperanza de la utilidad o un criterio multicriterio.

### 4. Heurísticas y enfoques aproximados

En muchas situaciones reales, la complejidad hace que sea **impracticable** obtener la solución óptima bajo el criterio de valor esperado de utilidad. Además, los datos disponibles para estimar  $p(\omega)$  o  $p(z \mid \omega)$  pueden ser **muy limitados** o ruidosos. En estos casos, se utilizan **heurísticas** o **reglas de dedo** que aproximan el proceso de decisión.

#### 4.1 Heurísticas de elección de decisión

##### 1. **Máximo verosímil** ("most likely state"):

- Estimar cuál  $\omega$  es más probable dado  $Z=z$  y tomar la decisión óptima suponiendo que ese es el estado real.
- $$\omega_{\text{ML}}(z) = \arg\max_{\omega} p(\omega \mid z)$$
- Limitación: ignora la incertidumbre residual sobre el resto de estados.

##### 2. **Valor Esperado Simplificado**:

- Asumir que las posibles divergencias de  $\omega$  respecto a la más probable son poco relevantes, y calcular la utilidad esperada de forma agregada pero con un modelo simplificado (tal vez ignorando correlaciones).

### 3. Reglas de umbrales:

- Basadas en correlaciones directas entre  $z$  y ciertos outcomes, estableciendo que si  $z$  supera un cierto umbral (o combina ciertos valores), entonces se elige  $d_A$ ; de lo contrario, se elige  $d_B$ .

### 4. Minimax o Maximin:

- Seleccionar  $d$  que **maximice** la utilidad mínima posible (o minimice el máximo costo). Se ignoran probabilidades, priorizando robustez ante un "peor caso" plausible.

## 4.2 Heurísticas de inferencia con datos escasos

- **Frecuencias empíricas:** Usar conteos y correlaciones directas a partir de datos limitados:  
$$\hat{p}(\omega \mid z) \approx \frac{\text{\# de observaciones con } (\omega, z)}{\text{\# total de observaciones con } z}$$
- **Suavizado (smoothing):** Añadir pseudo-cuentas (Dirichlet, Laplace) para evitar probabilidades nulas en muestras pequeñas.
- **Expert-based:** Incorporar conocimiento experto o "best guesses" cuando los datos son insuficientes.

---

## 5. Proceso sistemático de diseño de un problema de decisión estática

Cuando enfrentamos un **problema real** y queremos **diseñar** (o "mapear") un modelo de decisión estática bajo incertidumbre:

### 1. Recolección de información:

- Identificar las **variables de interés** (incertidumbre principal).
- Determinar **qué observaciones** o "proxy" pueden estar disponibles.
- Definir los **factores** que determinan la **utilidad** o **pérdida**.

### 2. Abstracción y simplificación:

- Delimitar un conjunto **manejaable** de **estados**  $\Omega$ .
- Establecer el conjunto de **decisiones**  $D$ .
- Reducir la complejidad de  $p(\omega)$  y  $p(z \mid \omega)$  con suposiciones (e.g. independencia, distribuciones paramétricas, etc.).

### 3. Formulación matemática:

- Especificar la **función de utilidad**  $U(\omega, d)$  o un **vector de métricas** si es un problema multicriterio.
- Incorporar la **probabilidad**  $p(\omega \mid z)$  si la acción puede depender de  $z$ .

### 4. Búsqueda de la solución:

- Aplicar el **criterio** de decisión apropiado (valor esperado, maximin, etc.).

- Emplear **heurísticas** cuando el espacio de decisiones o la estimación de probabilidades sea muy grande o incierta.

## 5. Validación y ajuste:

- Verificar si el modelo se ajusta a la realidad o si las simplificaciones resultan en decisiones poco robustas.
- Iterar si es posible.

## 6. Ejemplo ilustrativo (genérico)

Para hacer más concreto el proceso, supongamos un escenario **abstracto**:

- **Decisiones:**  $D = \{d_1, d_2, d_3\}$ .
- **Estados:**  $\Omega = \{\omega_1, \omega_2, \omega_3\}$ .
- **Utilidad:**  

$$U(\omega_i, d_j) = u_{ij}$$

$$\quad \text{para } i, j \in \{1, 2, 3\}$$
- **Distribución a priori:**  $p(\omega_1) = 0.4,; p(\omega_2) = 0.3,; p(\omega_3) = 0.3$

Supongamos, además, un **proxy**  $Z$  que puede tomar valores  $\{z_a, z_b\}$ . La regla bayesiana (o un modelo heurístico) nos permite estimar:

$$p(\omega_i \mid z_a),$$

$$\quad$$

$$p(\omega_i \mid z_b)$$

El decisor, una vez observa  $Z=z_a$ , elige  $d^*(z_a)$ . Similarmente para  $z_b$ . Se evalúa la utilidad esperada:

PROF

$$\mathbb{E}[U(d \mid z_a)] = \sum_{i=1}^3 p(\omega_i \mid z_a) U(\omega_i, d)$$

Si la decisión **depende** de  $Z$ , definimos una **política**  $\delta$  tal que:

$$\delta(z_a) = d_j, \quad$$

$$\delta(z_b) = d_k$$

La **utilidad esperada global** de la política  $\delta$  (antes de observar  $Z$ ) se calcula ponderando la probabilidad de cada valor de  $Z$ :

$$\mathbb{E}[U(\delta)] = \sum_{z \in \{z_a, z_b\}} p(z) \Bigl[ \sum_{i=1}^3 p(\omega_i \mid z) U(\omega_i, \delta(z)) \Bigr]$$

$z)U(\omega_i, \delta(z))$   
\$

La **política óptima**  $\delta^*$  sería la que maximiza esta esperanza.

---

## 7. Conclusiones y perspectivas

La **toma de decisiones estática bajo incertidumbre** es un marco fundamental para modelar y **resolver** problemas donde:

1. El decisor **no** puede cambiar su acción tras observar la realización de  $\omega$  (o bien no tiene un proceso iterativo).
2. Existen datos o información incompleta (proxy) que se pueden utilizar para **inferir probabilidades** sobre los estados.
3. La incertidumbre se gestiona usando una combinación de **teoría de la probabilidad** (idealmente Bayes) y **heurísticas** (cuando el modelo es complejo o los datos son escasos).

La clave está en la **abstracción** adecuada del problema:

- Definir con cuidado la **utilidad** o las **métricas** que valoran el outcome.
- Entender cómo las **observaciones** (proxy) se relacionan con la **incertidumbre** (estados).
- Emplear métodos de **optimización** basados en el **valor esperado** o criterios alternos (p.ej. maximin) según la preferencia de riesgo.
- Incorporar **heurísticas** cuando sea difícil o costoso computar la solución exacta o ajustar un modelo probabilístico complejo.

Este tipo de abordaje es agnóstico a la naturaleza específica del problema (podría tratarse de logística, ingeniería, gestión de riesgos, etc.), siempre que podamos identificar los estados inciertos, las decisiones, la información parcial y la manera de valorarlas. Con esta guía, el lector puede reconocer la estructura subyacente en problemas reales y traducirlos a un problema de decisión estática bajo incertidumbre, para luego aplicar las herramientas y heurísticas aquí descritas.

---

## Bibliografía

Raiffa, H. & Schlaifer, R. (1961). Applied Statistical Decision Theory.

Berger, J. O. (1985). Statistical Decision Theory and Bayesian Analysis.

Keeney, R. L. & Raiffa, H. (1976). Decisions with Multiple Objectives: Preferences and Value Trade-offs